RELAZIONE TECNICA

Flower Recognition

Classificazione binaria Daisy / Dandelion con CNN e Transfer Learning

GreenTech Solutions Ltd. | Progetto Finale Modulo Computer Vision

0.9831	0.9720	0.9834	0.0301
F1 macro (TTA)	F1 macro (test)	F1 macro (val)	ECE (calibrazione)

Autore	Francesco Scarano
Data	Marzo 2026
Best Backbone	**ConvNeXt-Tiny**

1. Introduzione e Contesto

Il presente documento descrive lo sviluppo e la valutazione del progetto Flower Recognition, realizzato per GreenTech Solutions Ltd. nell'ambito del modulo di Computer Vision del Master in AI Engineering. Il progetto ha l'obiettivo di sviluppare un sistema di classificazione automatica di immagini di fiori in grado di distinguere tra due specie: Daisy (margherita) e Dandelion (tarassaco).

Il sistema proposto è basato su tecniche di computer vision e transfer learning, utilizzando reti neurali convoluzionali (CNN) pre-addestrate e successivamente adattate al dominio specifico del dataset tramite fine-tuning. L'obiettivo del progetto è valutare l'efficacia di architetture CNN moderne nel contesto di un dataset di dimensioni relativamente contenute, analizzando non solo le prestazioni di classificazione ma anche aspetti fondamentali per l'impiego operativo di modelli di machine learning, quali calibrazione delle probabilità, interpretabilità del modello e robustezza rispetto a variabilità delle immagini.

1.1 Motivazione e caso d'uso

Il riconoscimento automatico di specie vegetali a partire da immagini rappresenta un'applicazione rilevante nel settore AgriTech. Tecniche di computer vision possono supportare il monitoraggio delle colture, migliorare i processi di controllo qualità nelle filiere florovivaistiche e abilitare applicazioni di precision farming, in cui sistemi automatici assistono gli operatori nell'identificazione e nella gestione delle piante.

In questo contesto, la classificazione binaria tra Daisy e Dandelion rappresenta un caso studio controllato ma significativo, utile per validare l'intero approccio metodologico di sviluppo del modello. Questo scenario consente di analizzare in modo chiaro le diverse fasi della pipeline di machine learning — dalla preparazione dei dati al training del modello, fino alla valutazione delle prestazioni e alla calibrazione delle probabilità — prima di estendere l'approccio a problemi di classificazione multi-classe su dataset più complessi e diversificati.

1.2 Stack tecnologico

- PyTorch 2.x + PyTorch Lightning — framework di training
- timm (PyTorch Image Models) — backbone pre-addestrati
- Albumentations — data augmentation
- scikit-learn — metriche, threshold tuning
- pytorch-grad-cam — visualizzazione Grad-CAM
- Apple MPS (Metal Performance Shaders) — accelerazione GPU su Apple Silicon

2. Dataset

2.1 Descrizione

Il dataset utilizzato nel progetto è stato scaricato dalla sorgente ufficiale del progetto, ospitata su **Amazon S3**. Esso contiene **1.821 immagini RGB a risoluzione variabile**, raffiguranti due specie di fiori: **Daisy (margherita)** e **Dandelion (tarassaco)**.

Le immagini sono già organizzate in tre split standard — **training**, **validation** e **test** — consentendo una separazione chiara tra le fasi di apprendimento del modello, la selezione degli iperparametri e la valutazione finale delle prestazioni.

La distribuzione delle immagini per classe e per split è riportata nella **Tabella 1**.

Split	Daisy	Dandelion	Totale
Train	529	746	1.275
Validation	163	201	364
Test	77	105	182

Tabella 1 — Distribuzione del dataset per split e classe

Il dataset presenta un **moderato sbilanciamento tra le due classi** (circa **41% Daisy e 59% Dandelion**), gestito durante la fase di training tramite l'utilizzo di **WeightedRandomSampler**, al fine di bilanciare la distribuzione delle classi nei batch di addestramento.

La suddivisione del dataset segue una proporzione approssimativa **70/20/10 tra training, validation e test**, una configurazione comunemente utilizzata nei workflow di machine learning per garantire un equilibrio tra quantità di dati disponibili per l'apprendimento del modello e affidabilità della valutazione finale.

Il **test set è stato mantenuto completamente isolato durante tutte le fasi di sviluppo del modello** ed è stato utilizzato esclusivamente per la valutazione finale delle prestazioni.

2.2 Preprocessing e pulizia

Il dataset originale estratto da archivio.tar.gz presentava 1.842 file di metadati macOS (._* e .DS_Store) distribuiti in tutta la struttura di directory. Questi file avrebbero causato UnidentifiedImageError durante il caricamento. Il cleanup è stato eseguito con os.walk ricorsivo prima di qualsiasi operazione di training.

Il dataset presenta un leggero sbilanciamento di classe (Daisy 41% / Dandelion 59%). Per compensarlo è stato adottato un WeightedRandomSampler sul DataLoader di training, che bilancia la frequenza con cui ciascuna classe viene campionata ad ogni epoca.

2.3 Data Augmentation

La pipeline di augmentation (Albumentations) differenziata per split:

- Training: RandomResizedCrop(224), HorizontalFlip, ColorJitter, GaussNoise, Normalize
- Validation / Test: Resize(256) + CenterCrop(224), Normalize

I valori di media e deviazione standard per la normalizzazione sono stati ottenuti direttamente dal modello backbone tramite timm.data.resolve_model_data_config(), garantendo coerenza con il pre-training su ImageNet-1k.

2.4 Limitazioni del dataset

Nonostante il dataset sia adeguato allo sviluppo di un prototipo di classificazione binaria, presenta alcune limitazioni che potrebbero influenzare la generalizzazione del modello in scenari reali.

Soggetti prevalentemente centrati

Molte immagini mostrano il fiore al centro dell'inquadratura, con composizione fotografica relativamente ordinata. In applicazioni reali, soprattutto con acquisizione da dispositivi mobili, il soggetto potrebbe essere decentrato o parzialmente fuori campo.

Numero limitato di occlusioni

Il dataset contiene poche immagini in cui il fiore è parzialmente coperto da elementi naturali (foglie, erba, altri fiori). Questo riduce la variabilità visiva disponibile durante il training.

Condizioni di illuminazione relativamente uniformi

Le immagini presentano condizioni di luce generalmente favorevoli e relativamente omogenee. Situazioni con illuminazione molto intensa, ombre profonde o controluce sono scarsamente rappresentate.

Dataset fotografico controllato

Il dataset deriva da immagini fotografiche curate e non da acquisizioni dirette in campo agricolo. In un contesto reale, immagini scattate da operatori con smartphone possono includere rumore, motion blur, inclinazioni della camera o composizioni meno strutturate.

Per mitigare queste limitazioni, future iterazioni del progetto potrebbero includere:

- raccolta di immagini di campo in condizioni operative reali
- ampliamento della pipeline di data augmentation (ad esempio occlusion augmentation, random shadow, motion blur)
- utilizzo di dataset multi-specie più ampi per aumentare la variabilità visiva.

3. Architettura del Sistema

3.1 Strategia di Transfer Learning

È stata adottata una strategia di **fine-tuning a due fasi**:

- Fase 1 (epoche 0-4): backbone completamente frozen, si addestra solo la classification head (lr=1e-3). Permette alla head di convergere senza distruggere i pesi pre-addestrati.
- Fase 2 (epoche 5-25): backbone sbloccato con learning rate discriminativi — backbone (lr=1e-5) vs head (lr=1e-4). Il backbone si adatta lentamente al dominio specifico, la head consolida.

3.2 Classification Head

La head è un Sequential con BatchNorm1d, Dropout(0.3) e Linear(features_dim, 1). L'output è un singolo logit (BCEWithLogitsLoss), più stabile numericamente rispetto a softmax binario e compatibile con il threshold tuning.

3.3 Scheduler e Ottimizzatore

Ottimizzatore: AdamW con weight_decay=1e-4. Scheduler: LambdaLR con cosine annealing a due fasi, sincronizzato con il momento di unfreeze del backbone. Gradient clipping con max_norm=1.0 per prevenire instabilità su MPS.

3.4 Backbone testati

Sono stati valutati quattro backbone in ablation study:

Backbone	Params	Top-1 ImageNet	Note
EfficientNet-B0	4.0 M	77.7%	Baseline leggero
EfficientNet-B2	7.7 M	80.6%	Scaling EfficientNet
ResNet-50	25.6 M	80.9%	Architettura classica
ConvNeXt-Tiny	28.6 M	82.1%	**Best — architettura moderna**

Tabella 2 — Backbone in ablation study

4. Risultati Sperimentali

4.1 Ablation Study — Confronto backbone

L'ablation study ha confrontato i quattro backbone su validation set con threshold fissa a 0.50. ConvNeXt-Tiny ha dominato nettamente con F1 macro pari a 0.9834, superando di 5 punti percentuali il secondo classificato (EfficientNet-B2).

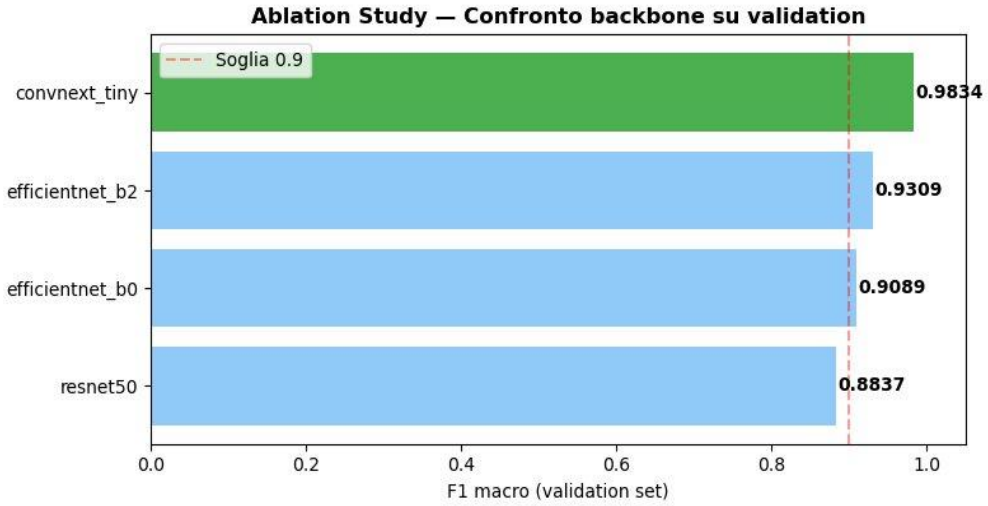

Figura 1 — Ablation study: F1 macro su validation set per backbone

4.2 Threshold Tuning

Il threshold di classificazione è stato ottimizzato sul validation set con sweep da 0.25 a 0.75 (step 0.01). Il threshold ottimale individuato è **0.48**, che migliora il F1 macro da 0.9834 a 0.9861. Lo spostamento dal default 0.50 compensa il lieve bias del modello verso la classe maggioritaria (Dandelion).

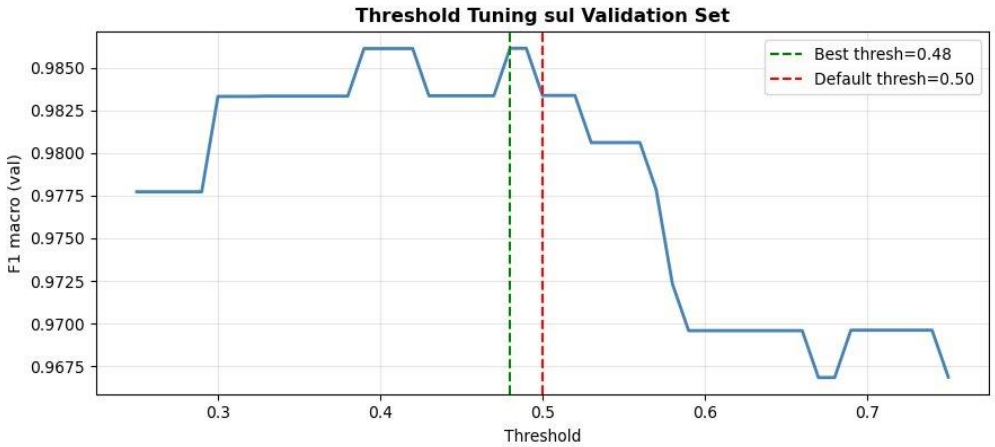

Figura 2 — Threshold tuning: F1 macro vs threshold sul validation set

4.3 Valutazione sul Test Set

Il test set è stato utilizzato **una sola volta**, al termine della selezione del backbone e del threshold — in accordo con le best practice di machine learning per evitare data leakage. Il modello ConvNeXt-Tiny con threshold 0.48 raggiunge F1 macro **0.9720** sul test set.

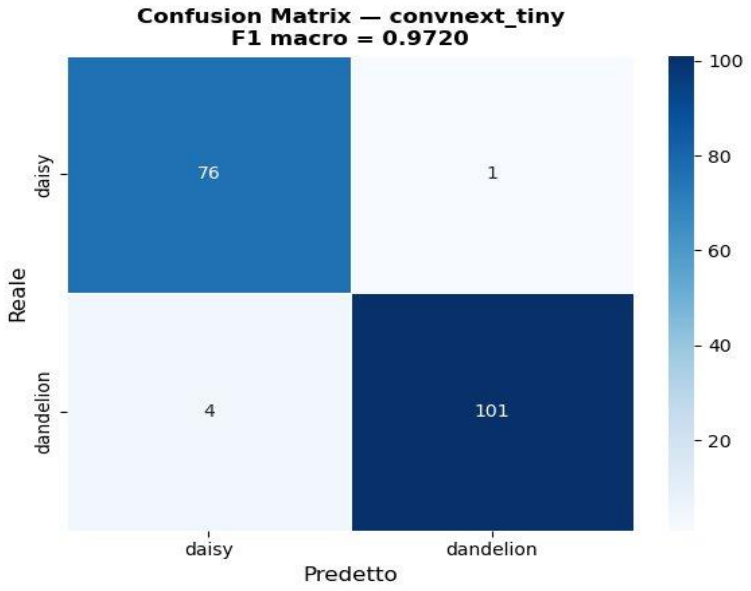

Figura 3 — Confusion Matrix — ConvNeXt-Tiny (test set, F1 macro = 0.9720)

Classe	Precision	Recall	F1-score	Support
daisy	0.95	0.99	0.97	77
dandelion	0.99	0.96	0.98	105
macro avg	0.97	0.97	0.97	182
weighted avg	0.97	0.97	0.97	182

Tabella 3 — Classification Report (threshold = 0.48, test set)

4.4 Test Time Augmentation (TTA)

Il TTA è stato applicato con 4 varianti geometriche (originale, flip orizzontale, flip verticale, flip combinato), mediando le probabilità predette. Il guadagno ottenuto è **+0.0111 di F1 macro**, portando il risultato finale a **0.9831**. Il miglioramento è attribuibile alla riduzione della varianza sulle immagini con predizione incerta (margine di probabilità vicino al threshold).

0.9720	0.9831	+0.0111	0.48
F1 Test (no TTA)	F1 Test (con TTA)	Guadagno TTA	Threshold ottimale

5. Calibrazione del Modello

La calibrazione misura quanto le confidence scores (probabilità) del modello riflettono le frequenze reali di accuratezza. Un modello ben calibrato con confidence 0.9 dovrebbe classificare correttamente il 90% delle predizioni in quel bucket. L'**Expected Calibration Error (ECE)** sintetizza questo scostamento con un singolo scalare.

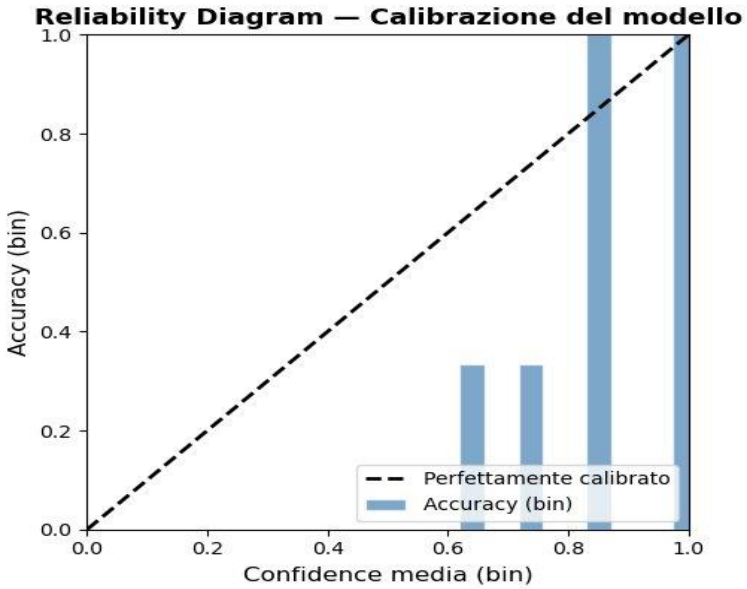

Figura 4 — Reliability Diagram: calibrazione del modello ConvNeXt-Tiny

Il modello ottiene un **ECE = 0.0301**, indicando una calibrazione eccellente. La maggior parte delle predizioni cade nel bucket di alta confidence (0.9-1.0) con accuracy corrispondente, coerentemente con la diagonale del modello perfettamente calibrato. Un ECE sotto 0.05 è generalmente considerato ottimo per applicazioni reali.

6. Riepilogo Comparativo

Backbone	F1 Val	F1 Test	F1 TTA	Threshold
convnext_tiny	**0.9834**	**0.9720**	**0.9831**	**0.48**
efficientnet_b2	0.9309	—	—	—
efficientnet_b0	0.9089	—	—	—
resnet50	0.8837	—	—	—

Tabella 4 — Riepilogo risultati ablation study (la riga verde indica il best model)

Solo ConvNeXt-Tiny è stato valutato sul test set, in quanto il test set viene utilizzato unicamente per la valutazione finale del modello selezionato su validation — non come criterio di selezione.

7. Analisi Qualitativa — Grad-CAM

Le visualizzazioni Grad-CAM (Gradient-weighted Class Activation Mapping) mostrano le regioni dell'immagine che il modello attiva maggiormente per la classificazione. Sono state generate per il layer **backbone.stages[-1].blocks[-1]** di ConvNeXt-Tiny, che corrisponde all'ultimo blocco convoluzionale del backbone — il livello di astrazione più elevato prima della classification head.

Le mappe di attivazione confermano che il modello ha appreso feature semanticamente significative: per Daisy si attiva la struttura petalo-pistillo, per Dandelion la forma sferica del capolino. Questo esclude che la rete stia apprendendo artifact di sfondo o bias di illuminazione.

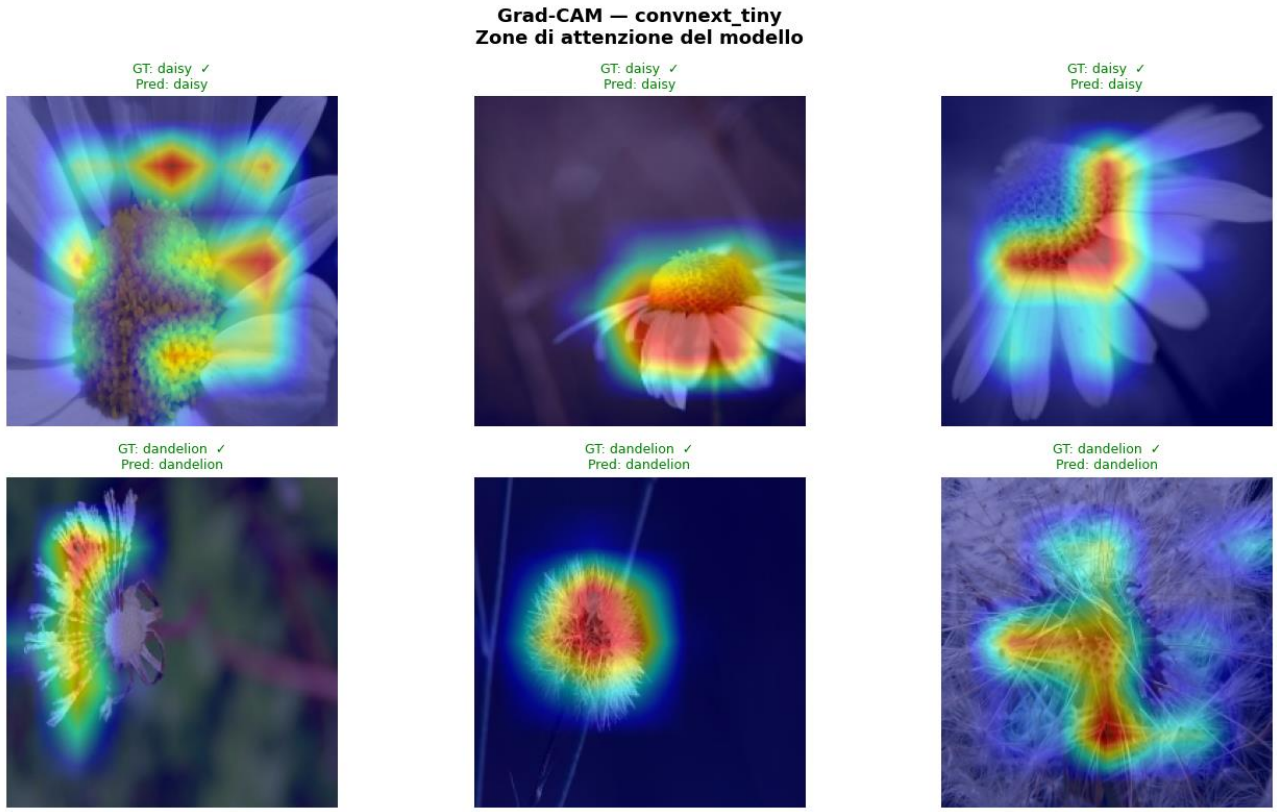

Figura 5 — Visualizzazioni Grad-CAM per il modello ConvNeXt-Tiny

Le mappe di attivazione evidenziano le regioni dell'immagine che contribuiscono maggiormente alla decisione del modello. Le aree rosse indicano le zone con maggiore rilevanza per la classificazione. Nei casi mostrati, il modello concentra l'attenzione su caratteristiche morfologiche distintive delle due specie: il disco centrale e la struttura dei petali per Daisy, e la forma sferica del capolino per Dandelion.

Le visualizzazioni confermano che il modello apprende **feature semanticamente rilevanti** e non semplici correlazioni con lo sfondo. Nel caso delle margherite, l'attivazione si concentra principalmente nella regione centrale del fiore e lungo la struttura dei petali. Per i tarassaci, invece, il modello focalizza l'attenzione sulla struttura radiale del capolino e sui filamenti caratteristici del seme. Questo comportamento suggerisce che la rete abbia appreso rappresentazioni visive coerenti con le caratteristiche botaniche distintive delle due specie.

7.1 Robustezza e generalizzazione del modello

Sebbene il modello raggiunga prestazioni elevate sul test set, è importante valutare la sua capacità di generalizzare a condizioni operative reali, tipiche di applicazioni AgriTech. In scenari di campo, le immagini possono presentare variabilità significativa rispetto al dataset utilizzato per il training.

In particolare, la robustezza del modello può essere influenzata da diversi fattori:

Illuminazione variabile

In ambiente reale l'illuminazione può cambiare significativamente (luce diretta del sole, ombre, controluce o condizioni nuvolose). Sebbene la pipeline di data augmentation includa variazioni cromatiche e di contrasto, condizioni di illuminazione estreme potrebbero alterare la percezione delle caratteristiche morfologiche del fiore.

Occlusioni parziali

In contesto naturale i fiori possono essere parzialmente coperti da foglie, steli o altri elementi vegetali. Il dataset utilizzato contiene poche immagini con occlusioni rilevanti, pertanto il comportamento del modello in tali condizioni potrebbe degradare.

Fiori parzialmente visibili

In molte situazioni operative il fiore può essere solo parzialmente inquadrato oppure tagliato dai bordi dell'immagine. La pipeline di preprocessing (Resize + CenterCrop) privilegia immagini con soggetto centrale e completo; immagini con soggetto decentrato o incompleto potrebbero risultare più difficili da classificare.

Variabilità nella distanza dalla camera

La distanza tra camera e soggetto influisce sulla scala del fiore nell'immagine. Il modello è stato addestrato principalmente su immagini in cui il fiore occupa una porzione significativa del frame. In presenza di fiori molto piccoli rispetto allo sfondo, le feature discriminative potrebbero risultare meno evidenti.

Nel complesso, il modello mostra buone capacità di generalizzazione nel contesto del dataset disponibile, ma ulteriori validazioni su immagini raccolte in ambiente reale sarebbero necessarie per garantire prestazioni robuste in scenari operativi.

7.2 Ambiente di esecuzione e riproducibilità

Il training principale del modello è stato eseguito localmente su **MacBook Pro con Apple Silicon M3**, utilizzando il backend **MPS** (**Metal Performance Shaders**) fornito da PyTorch per l'accelerazione GPU su architettura Apple.

Il notebook è stato successivamente testato anche in ambiente **Google Colab con GPU CUDA**, al fine di verificarne la corretta esecuzione e la portabilità in un contesto cloud.

È importante osservare che modelli di deep learning possono presentare **lievi variazioni nei risultati tra ambienti hardware differenti**, anche a parità di seed casuale, a causa di differenze nei backend numerici (MPS vs CUDA), nelle modalità di precisione del calcolo (FP32 vs mixed precision) e nelle versioni delle librerie utilizzate.

Durante i test su Google Colab sono state osservate piccole variazioni nei valori di F1-score rispetto ai risultati ottenuti localmente. Tuttavia, **le prestazioni complessive del modello e il ranking tra le architetture testate rimangono coerenti**, confermando la validità delle conclusioni sperimentali.

A causa delle **limitazioni di utilizzo della GPU nella versione gratuita di Google Colab**, non è stato possibile eseguire ulteriori run completi di addestramento in ambiente cloud. Il notebook fornito rimane comunque pienamente eseguibile e riproducibile.

8. Conclusioni

Il sistema sviluppato ha dimostrato prestazioni molto elevate nel task di classificazione binaria tra **Daisy** e **Dandelion**, raggiungendo un **F1 macro pari a 0.9831 con Test Time Augmentation (TTA)**. Le probabilità prodotte dal modello risultano inoltre ben calibrate, come evidenziato dal valore di **Expected Calibration Error (ECE) pari a 0.0301**, indicativo di una buona affidabilità delle stime probabilistiche.

L'intera pipeline di machine learning è stata progettata con un approccio metodologico rigoroso, separando chiaramente le fasi di training, validazione e test al fine di evitare fenomeni di data leakage. La selezione dell'architettura, l'ottimizzazione della soglia decisionale e le tecniche di inferenza sono state tutte determinate esclusivamente sul validation set, mentre il test set è stato utilizzato unicamente per la valutazione finale del modello.

Nel complesso, il processo di training ha mostrato una **convergenza stabile**, con metriche di validazione elevate e consistenti rispetto alle prestazioni osservate sul test set, suggerendo una buona capacità di generalizzazione del modello nonostante le dimensioni relativamente contenute del dataset.

Ogni componente della pipeline ha contribuito in modo misurabile e motivato al risultato finale:

Componente	Contributo
ConvNeXt-Tiny backbone	Architettura moderna con inductive bias ridotto, superiore a ResNet e EfficientNet su questo dataset
WeightedRandomSampler	Compensazione dello sbilanciamento 41/59% senza sovracampionamento
Fine-tuning a due fasi	Convergenza stabile: head prima, poi backbone con LR discriminativi
Threshold tuning (0.48)	Correzione del bias verso la classe maggioritaria sul validation set
TTA (4 flip)	+0.0111 F1 macro riducendo varianza sulle predizioni marginali

Tabella 5 — Contributo di ogni componente del pipeline

L'analisi qualitativa tramite **Grad-CAM** ha inoltre evidenziato che il modello basa le proprie decisioni su regioni semanticamente rilevanti dell'immagine, come la struttura del disco centrale nelle margherite e la forma radiale del capolino nei tarassaci, suggerendo che la rete abbia appreso feature visive coerenti con le caratteristiche botaniche distintive delle due specie.

Nonostante le prestazioni molto elevate sul dataset disponibile, la validazione su immagini acquisite in **condizioni operative reali** rappresenta il passo successivo fondamentale per valutare la robustezza del sistema in contesti AgriTech, dove variabilità di illuminazione, occlusioni e inquadrature meno controllate possono influenzare la qualità dell'inferenza.

8.1 Sviluppi futuri

Le possibili evoluzioni del progetto includono:

- estensione del modello a **classificazione multi-classe** utilizzando dataset più ampi, come *Oxford 102 Flowers*
- applicazione di tecniche di **Temperature Scaling** per migliorare ulteriormente la calibrazione delle probabilità
- **deployment del modello tramite esportazione ONNX** per inferenza efficiente su dispositivi edge o sistemi embedded
- integrazione di strategie di **Active Learning** per ridurre il costo di annotazione durante l'espansione del dataset con nuove specie.

Appendice — Configurazione Sperimentale

Parametro	Valore
Batch size	32
Max epoche	25
Frozen epoche	5
LR head (fase 1)	1e-3

Parametro	Valore
LR backbone (fase 2)	1e-5
LR head (fase 2)	1e-4
Weight decay	1e-4
Dropout	0.3
Optimizer	AdamW
Scheduler	LambdaLR cosine (2 fasi)
Gradient clip	1.0
Image size	224 × 224
Precision	32-bit (MPS)
Early stopping patience	5 epoche (monitor: val_f1_macro)
Hardware	Apple M-series (MPS)

Tabella A.1 — Iperparametri del training